

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

Прогнозирование медицинских страховых выплат

2026 z.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ

Заведующий кафедрой _____ ИУ-5
(индекс)
_____ В.И. Терехов
(И.О. Фамилия)
« ____ » _____ 20 ____ г.

З А Д А Н И Е
на выполнение научно-исследовательской работы

по теме _____ Прогнозирование медицинских страховых выплат
Студент группы _____ Ковалев Егор Андреевич
(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)
учебная

Источник тематики (кафедра, предприятие, НИР) _____ кафедра

График выполнения НИР: 25% к ____ нед., 50% к ____ нед., 75% к ____ нед., 100% к ____ нед.

Техническое задание Произвести исследование решения задачи машинного обучения на основе материалов дисциплины, включающее поиск и выбор набора данных для построения моделей машинного обучения. На основе выбранного набора данных построить модели машинного обучения для решения или задачи классификации, или задачи регрессии.

Оформление научно-исследовательской работы:

Расчетно-пояснительная записка на 18 листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания « 10 » февраля 2026 г.

Руководитель НИР	_____	Ю.Е. Гапанюк
	(подпись, дата)	(И.О. Фамилия)
Студент	_____	Е.А. Ковалев
	(подпись, дата)	(И.О. Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	4
1. ПОСТАНОВКА ЗАДАЧИ	6
2. ОПИСАНИЕ НАБОРА ДАННЫХ	7
3. РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ.....	8
4. ПРЕДОБРАБОТКА ДАННЫХ.....	11
5. ПОСТРОЕНИЕ И ОЦЕНКА МОДЕЛЕЙ.....	12
6. ПОДБОР ГИПЕРПАРАМЕТРОВ	13
7. ВЕБ-ПРИЛОЖЕНИЕ	14
8. ЗАКЛЮЧЕНИЕ.....	16
9. СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	17

ВВЕДЕНИЕ

В современных условиях страховой бизнес сталкивается с необходимостью быстрой и точной оценки индивидуальных рисков клиентов для формирования справедливой тарифной политики. Автоматизация прогнозирования страховых выплат позволяет компаниям не только ускорить процесс выдачи полисов, но и минимизировать финансовые потери, связанные с ошибками человеческого фактора. Использование методов машинного обучения в этой области становится стандартом индустрии, так как алгоритмы способны выявлять сложные нелинейные зависимости между социально-демографическими характеристиками человека и потенциальными затратами на его медицинское обслуживание.

Данная научно-исследовательская работа направлена на проведение комплексного исследования процесса разработки прогностических моделей. Основная цель заключается в построении и сравнительном анализе различных алгоритмов машинного обучения для решения задачи регрессии. В качестве объекта исследования выступают персональные данные пациентов, включая такие критические факторы, как возраст, индекс массы тела (BMI) и наличие вредных привычек. Исследование позволяет на практике оценить, как различные архитектуры моделей – от классических линейных методов до современных ансамблей – справляются с интерпретацией медицинских и демографических данных.

Методология работы охватывает полный жизненный цикл разработки интеллектуальной системы: от глубокого разведочного анализа и предобработки сырых данных до финальной оптимизации моделей. Особое внимание в НИРС уделяется этапу инженерного анализа признаков и подбору гиперпараметров с использованием методов кросс-валидации. Это позволяет не только добиться высокой точности прогноза (минимизации метрик MAE и MSE), но и обеспечить устойчивость модели к новым данным, исключая риск переобучения. Сравнение базовых решений с настроенными ансамблями наглядно демонстрирует

преимущество современных подходов в задачах с разнородными признаками.

Практическая значимость исследования подтверждается созданием интерактивного веб-интерфейса, который служит инструментом визуализации и верификации полученных результатов. Разработанное приложение позволяет в реальном времени наблюдать, как изменение входных параметров пользователя или корректировка внутренних настроек алгоритма (таких как скорость обучения или глубина деревьев) влияют на итоговый финансовый прогноз. Такой подход делает процесс машинного обучения прозрачным и доступным для конечного пользователя, превращая теоретическую модель в готовый прототип бизнес-решения.

1. ПОСТАНОВКА ЗАДАЧИ

Основной целью данной научно-исследовательской работы является разработка и программная реализация системы интеллектуального анализа данных для автоматизированного прогнозирования индивидуальных медицинских страховых выплат. Задача классифицируется как классическая задача восстановления регрессии (regression), где на основе вектора входных признаков, характеризующих социально-демографический и физический профиль клиента, необходимо предсказать непрерывную величину ожидаемых финансовых затрат (charges). В рамках исследования требуется не только добиться высокой точности предсказания, но и провести сравнительный анализ эффективности различных архитектур алгоритмов.

Объектом исследования выступает совокупность обезличенных данных о клиентах страховой компании, включающая такие параметры, как возраст, пол, индекс массы тела, наличие детей, статус курения и географический регион. Предметом исследования являются методы и алгоритмы машинного обучения, способные выявлять закономерности в данных медицинского страхования. В ходе работы необходимо решить проблему предобработки разнородных данных, включая нормализацию числовых шкал и кодирование категориальных признаков, что является критически важным для корректного обучения математических моделей.

Техническое задание на исследование включает выполнение ряда обязательных этапов и соблюдение строгих критериев качества. Необходимо реализовать процесс построения не менее пяти различных моделей машинного обучения, две из которых должны базироваться на ансамблевых методах. Процесс разработки должен включать этап создания базового решения (baseline) и последующую оптимизацию гиперпараметров с применением кросс-валидации. Для количественной оценки результатов предписано использование как минимум трех независимых метрик (MAE, MSE, R^2), что обеспечит всесторонний аудит точности и надежности разработанных систем.

Итоговым результатом НИРС должен стать не только аналитический отчет с выводами о наиболее эффективных моделях, но и работающий прототип веб-приложения. Данное приложение должно обеспечивать интерактивное взаимодействие с моделью, позволяя пользователю изменять параметры её архитектуры и мгновенно оценивать изменения в прогнозных способностях. Таким образом, задача переходит из плоскости чистого теоретического анализа в область разработки готового программного продукта, пригодного для демонстрации и потенциального использования в качестве системы поддержки принятия решений.

2. ОПИСАНИЕ НАБОРА ДАННЫХ

Для проведения исследования был выбран открытый набор данных «Medical Cost Personal Datasets», который широко используется в сообществе Data Science для отработки навыков решения задач регрессии. Данные представляют собой статистическую выборку из страховых архивов США и содержат информацию о 1338 клиентах. Выбор данного датасета обоснован наличием в нем как количественных, так и качественных характеристик, что позволяет в полной мере продемонстрировать возможности современных алгоритмов машинного обучения по обработке разнородных признаков.

Набор данных включает семь основных столбцов. Целевой переменной является признак `charges` – сумма индивидуальных медицинских расходов, оплаченных по страховке. Входные признаки делятся на две категории: демографические (возраст, пол, регион проживания) и физические/социальные (индекс массы тела – BMI, количество детей, статус курильщика). Каждая из этих переменных несет важную прогностическую ценность. Например, возраст и ИМТ традиционно считаются ключевыми факторами риска в медицине, а статус курильщика напрямую влияет на вероятность наступления страхового случая.

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520

Рисунок 1 – строки датасета с названиями столбцов

Разнообразие признаков требует особого внимания к их формату. Признаки `age` и `bmi` являются непрерывными числовыми величинами, в то время как `sex`, `smoker` и `region` – категориальными данными разного типа (бинарными и многоклассовыми). Признак `children` является дискретным числовым. Такая структура данных идеально подходит для демонстрации работы различных методов предобработки, таких как стандартизация и унитарное кодирование (One-Hot Encoding), что является важной частью учебного исследования.

3. РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ

Первым этапом практической работы стало проведение визуального и статистического анализа данных для выявления скрытых закономерностей и аномалий. В ходе проверки структуры было подтверждено отсутствие пропущенных значений (`null-values`), что свидетельствует о высоком качестве исходной выборки. Был проведен первичный статистический анализ, который показал существенный разброс в целевой переменной `charges`: при среднем значении около 13 270 долларов, максимальные выплаты достигают более 63 000 долларов, что указывает на наличие «тяжелого» правого хвоста в распределении и возможную необходимость использования выбросоустойчивых моделей.


```
Проверка на пропуски:  
age          0  
sex          0  
bmi          0  
children     0  
smoker       0  
region       0  
charges      0  
dtype: int64
```

Рисунок 2 – проверка датасета на пропуски




Рисунок 3 – гистограмма плотности целевой величины

Визуализация распределения целевой переменной с помощью гистограммы и графика плотности подтвердила положительную асимметрию. Большинство страховых выплат сосредоточено в диапазоне до 15 000 долларов, однако наблюдаются отчетливые пики в более высоких ценовых сегментах.




Рисунок 4 – Матрица корреляций признаков

Корреляционный анализ, проведенный с использованием матрицы тепловых карт (heatmap), выявил наиболее сильные линейные зависимости. Ожидается, статус курильщика показал самую высокую положительную корреляцию с суммой выплат. Возраст клиента также продемонстрировал устойчивую положительную связь с целевой переменной, что подтверждает гипотезу о росте медицинских расходов по мере старения. Фактор индекса массы тела (BMI) показал умеренную корреляцию, однако его влияние значительно усиливается в сочетании с курением, что создает синергетический эффект и резко повышает стоимость страховки.

4. ПРЕДОБРАБОТКА ДАННЫХ

Процесс предобработки данных был организован с использованием профессионального инструментария – конвейеров (Pipelines) библиотеки Scikit-learn. Это позволило автоматизировать цепочку преобразований и гарантировать отсутствие утечки данных из тестовой выборки в обучающую. Для числовых признаков (age, bmi, children) была применена процедура стандартизации (StandardScaler). Это необходимо для того, чтобы привести данные к единому масштабу со средним значением 0 и стандартным отклонением 1, что критически важно для корректной работы линейных моделей и метода опорных векторов (SVR).

Категориальные признаки (sex, smoker, region) были преобразованы в числовой формат с помощью метода унитарного кодирования (OneHotEncoder). Это позволило представить каждое текстовое значение в виде набора бинарных признаков (0 и 1), что делает их пригодными для обработки математическими алгоритмами. Применение ColumnTransformer обеспечило параллельную обработку различных типов столбцов в рамках единого потока данных, сохраняя целостность и воспроизводимость эксперимента.

Перед началом обучения набор данных был разделен на обучающую (training) и тестовую (testing) выборки в соотношении 80% к 20%. Такое разделение является стандартом в машинном обучении и позволяет оценить обобщающую способность моделей на данных, которые они не видели в процессе обучения. В результате предобработки исходный набор признаков был расширен до 11 колонок за счет развертывания категориальных переменных, что создало оптимальные условия для последующего этапа моделирования.

```
X = df.drop('charges', axis=1)
y = df['charges']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

numeric_features = ['age', 'bmi', 'children']
categorical_features = ['sex', 'smoker', 'region']

preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_features),
        ('cat', OneHotEncoder(), categorical_features)
    ])

```

Рисунок 5 – Стандартизация и кодирование датасета

5. ПОСТРОЕНИЕ И ОЦЕНКА МОДЕЛЕЙ

Для решения задачи были выбраны пять различных алгоритмов, представляющих разные подходы к машинному обучению. В качестве базового решения (baseline) была использована линейная регрессия. Для оценки нелинейных зависимостей были выбраны дерево решений и метод опорных векторов (SVR). Особое внимание в работе уделено ансамблевым методам – случайному лесу (Random Forest) и градиентному бустингу (Gradient Boosting). Использование ансамблей позволяет объединить прогнозы множества «слабых» моделей в одно мощное решение, что традиционно обеспечивает высокую точность в задачах с табличными данными.

Для оценки качества построенных моделей была выбрана система из трех метрик, каждая из которых отражает определенный аспект точности. Средняя абсолютная ошибка (MAE) интерпретируется как среднее отклонение прогноза в долларах, что максимально понятно для бизнеса. Среднеквадратичная ошибка (MSE) за счет возведения разностей в квадрат сильнее штрафует модель за крупные промахи. Наконец, коэффициент детерминации (R^2) показывает долю дисперсии целевой переменной, которую объясняет модель, где значение 1.0 соответствует идеальному прогнозу.

Результаты базового тестирования показали явное превосходство ансамблевых алгоритмов. Модель градиентного бустинга продемонстрировала наилучший показатель $R^2 \approx 0.88$, что говорит о высокой точности прогнозирования. Линейная регрессия показала себя достойно ($R^2 \approx 0.78$), подтверждая наличие сильных линейных трендов. Однако модель SVR без предварительной настройки показала крайне низкие результаты, что подчеркнуло необходимость тщательного подбора гиперпараметров для определенных типов алгоритмов в контексте данной задачи.

	MAE	R2
Linear Regression	4182.196512	0.779752
Decision Tree	3551.336863	0.696209
Random Forest	2728.028311	0.854374
Gradient Boosting	2490.412666	0.874835
SVR	8524.229918	-0.111271

Рисунок 6 – Сравнение метрик точности построенных моделей

6. ПОДБОР ГИПЕРПАРАМЕТРОВ

Этап оптимизации был сфокусирован на двух наиболее перспективных моделях – Random Forest и Gradient Boosting. Для поиска наилучшей конфигурации использовался метод решетчатого поиска (GridSearchCV) с встроенной пятикратной кросс-валидацией. Такой подход позволяет не просто найти оптимальные значения параметров, но и убедиться, что выбранная модель стабильно работает на разных подмножествах данных. В ходе эксперимента варьировались такие параметры, как количество деревьев в ансамбле (`n_estimators`), максимальная глубина деревьев (`max_depth`) и скорость обучения (`learning_rate`).

Для модели случайного леса (Random Forest) было установлено, что ограничение максимальной глубины деревьев до 10 позволяет избежать переобучения и улучшить точность на тестовых данных. В случае градиентного бустинга подбор параметров показал, что стандартная конфигурация уже близка к оптимальной, однако небольшая корректировка глубины дерева позволила сделать модель более устойчивой к шумам в данных. Использование кросс-валидации гарантировало, что итоговые метрики являются объективными и не зависят от случайного разбиения данных.

Итоговое сравнение оптимизированных моделей подтвердило, что

Gradient Boosting остается лидером с минимальной ошибкой MAE около 2400 долларов. Это означает, что в среднем модель ошибается лишь на небольшую долю от общей стоимости страховки. Полученное улучшение по сравнению с базовыми решениями (baseline) подтвердило важность этапа тонкой настройки параметров для достижения максимальных бизнес-результатов в задачах предиктивной аналитики.




Рисунок 7 – Сравнение итоговых метрик полученных моделей

7. ВЕБ-ПРИЛОЖЕНИЕ

Завершающим этапом НИРС стала разработка веб-интерфейса на базе библиотеки Streamlit. Приложение было спроектировано как интерактивный инструмент для демонстрации возможностей машинного обучения. Интерфейс

разделен на две логические части: блок настройки параметров обучения и блок прогнозирования. Пользователь может в реальном времени изменять ключевые гиперпараметры модели градиентного бустинга, такие как количество итераций обучения и глубина решающих правил, и мгновенно видеть, как эти изменения влияют на точность (метрики MAE и R^2).

Функционал приложения включает в себя форму ввода данных нового клиента, где можно указать возраст, пол, индекс массы тела, количество детей, регион и статус курения. При нажатии кнопки расчета приложение использует предварительно обученный Pipeline (сохраненный в файл `best_model.pkl`) для мгновенного вычисления стоимости страхового полиса. Такой подход демонстрирует практическую применимость разработанной модели в реальных бизнес-процессах страховой компании, например, в качестве калькулятора на сайте.

Реализация веб-приложения позволила решить одну из ключевых задач НИРС – визуализацию зависимости качества модели от её параметров. Интерактивные графики и метрики в интерфейсе наглядно показывают, что чрезмерное усложнение модели (например, установка слишком большой глубины деревьев) может привести к падению точности на тестовых данных. Таким образом, приложение является не только демонстрационным, но и обучающим инструментом, иллюстрирующим фундаментальные концепции машинного обучения.




Рисунок 8 – Страница разработанного приложения

8. ЗАКЛЮЧЕНИЕ

В ходе выполнения типового исследования НИРС была успешно решена комплексная задача построения прогностической модели медицинских страховых выплат. Начиная с глубокого анализа исходных данных и заканчивая развертыванием веб-приложения, были пройдены все ключевые этапы жизненного цикла разработки интеллектуальной системы. Результаты исследования подтвердили гипотезу о том, что ансамблевые методы машинного обучения обладают наилучшим балансом точности и обобщающей способности для задач финансового прогнозирования на основе разнородных признаков.

Основным достижением работы является построение модели градиентного бустинга, которая способна объяснить около 88% дисперсии страховых выплат. Было доказано, что критически важными факторами при расчете стоимости страховки являются статус курильщика и возраст клиента, при этом их влияние носит нелинейный характер. Разработанная система предобработки данных на основе пайплайнов обеспечила надежность и легкость масштабирования решения, что позволило бесшовно интегрировать модель в интерактивное приложение.

Практическая значимость работы заключается в создании готового прототипа системы поддержки принятия решений для страховых организаций. Полученные навыки работы с библиотеками Scikit-learn, Pandas и Streamlit закладывают прочный фундамент для решения более сложных прикладных задач в области анализа данных. Дальнейшее развитие проекта может быть связано с использованием более глубоких нейронных сетей или интеграцией дополнительных признаков, таких как медицинская история пациента и наличие хронических заболеваний, что позволит еще сильнее снизить ошибку прогноза.

9. СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Géron, A. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow / A. Géron. – 2nd ed. – Sebastopol : O'Reilly Media, 2019. – 856 p.
2. Hastie, T. The Elements of Statistical Learning: Data Mining, Inference, and Prediction / T. Hastie, R. Tibshirani, J. Friedman. – 2nd ed. – New York : Springer, 2009. – 745 p.
3. McKinney, W. Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter / W. McKinney. – 3rd ed. – Sebastopol : O'Reilly Media, 2022. – 579 p.
4. Müller, A. C. Introduction to Machine Learning with Python: A Guide for Data Scientists / A. C. Müller, S. Guido. – Sebastopol : O'Reilly Media, 2016. – 400 p.
5. Рашка, С. Python и машинное обучение / С. Рашка, В. Мирджалили. – 3-е изд. – М. : Диалектика, 2020. – 848 с.
6. Вьюгин, В. В. Математические основы машинного обучения и прогнозирования / В. В. Вьюгин. – 2-е изд. – М. : МЦНМО, 2018. – 390 с.
7. Medical Cost Personal Datasets [Электронный ресурс] // Kaggle. – Режим доступа: <https://www.kaggle.com/datasets/mirichoi0218/insurance> (дата обращения: 01.06.2026).
8. Scikit-learn: Machine Learning in Python. Documentation [Электронный ресурс]. – Режим доступа: <https://scikit-learn.org/stable/documentation.html> (дата обращения: 01.06.2026).
9. Pandas – Python Data Analysis Library. Documentation [Электронный ресурс]. – Режим доступа: <https://pandas.pydata.org/docs/> (дата обращения: 01.06.2026).
10. NumPy Documentation [Электронный ресурс]. – Режим доступа: <https://numpy.org/doc/stable/> (дата обращения: 01.06.2026).
11. Matplotlib Documentation [Электронный ресурс]. – Режим доступа: <https://matplotlib.org/stable/contents.html> (дата обращения: 01.06.2026).
12. Seaborn: Statistical Data Visualization. Documentation [Электронный

ресурс]. – Режим доступа: <https://seaborn.pydata.org/> (дата обращения: 01.06.2026).

13. Scikit-learn. Ensemble Methods [Электронный ресурс]. – Режим доступа: <https://scikit-learn.org/stable/modules/ensemble.html> (дата обращения: 01.06.2026).

14. Scikit-learn. Model Evaluation: Quantifying the Quality of Predictions [Электронный ресурс]. – Режим доступа: https://scikit-learn.org/stable/modules/model_evaluation.html (дата обращения: 01.06.2026).

15. Scikit-learn. Tuning the Hyper-parameters of an Estimator [Электронный ресурс]. – Режим доступа: https://scikit-learn.org/stable/modules/grid_search.html (дата обращения: 01.06.2026).