

Обработка пропусков в данных в датасете Iris (Вариант 9)

Ковалев Е.А. гр. ИУ5-66Б

Импорт библиотек и загрузка данных

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_iris
np.random.seed(2026669)
```

```
iris = load_iris()
df = pd.DataFrame(iris.data, columns=iris.feature_names)
df['species'] = pd.Categorical.from_codes(iris.target,
iris.target_names)
df.head()
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
0	5.1	3.5	1.4	
1	4.9	3.0	1.4	
2	4.7	3.2	1.3	
3	4.6	3.1	1.5	
4	5.0	3.6	1.4	

	species
0	setosa
1	setosa
2	setosa
3	setosa
4	setosa

Подготовка данных

В исходном датасете нет пропусков, а целевая переменная species уже является категориальным признаком. Создадим дополнительно категориальный признак на основе

числового (petal length (cm)), а затем искусственно внесём пропуски в один количественный признак (sepal width (cm)) и в созданный категориальный признак.

```
# Создаём категориальный признак на основе числового
df['petal_size'] = pd.cut( df['petal length (cm)'], bins=[0, 2, 5,
10], labels=['small', 'medium', 'large'] )
df['petal_size'] = df['petal_size'].astype('object')
df.head()
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
0	5.1	3.5	1.4	0.2
1	4.9	3.0	1.4	0.2
2	4.7	3.2	1.3	0.2
3	4.6	3.1	1.5	0.2
4	5.0	3.6	1.4	0.2

```
species petal_size
0 setosa small
1 setosa small
2 setosa small
3 setosa small
4 setosa small
```

```
# Искусственно вносим пропуски (15% значений) в один количественный и
один категориальный признак
n = len(df)
missing_idx_num = np.random.choice(df.index, size=int(n * 0.15),
replace=False)
df.loc[missing_idx_num, 'sepal width (cm)'] = np.nan
missing_idx_cat = np.random.choice(df.index, size=int(n * 0.15),
replace=False)
df.loc[missing_idx_cat, 'petal_size'] = np.nan
df.isna().sum()
```

sepal length (cm)	0
sepal width (cm)	22
petal length (cm)	0
petal width (cm)	0
species	0
petal_size	22
dtype:	int64

Обработка пропусков

Количественный признак: sepal width (cm)

Заполним пропуски медианой признака. Медиана устойчива к выбросам и хорошо подходит для числовых признаков.

```
median_value = df['sepal width (cm)'].median()
df['sepal width (cm)'] = df['sepal width (cm)'].fillna(median_value)
print(f'Медиана: {median_value}')
```

Медиана: 3.0

Категориальный признак: petal_size

```
mode_value = df['petal_size'].mode()[0]
df['petal_size'] = df['petal_size'].fillna(mode_value)
print(f'Мода: {mode_value}')
```


Мода: medium

```
df.isna().sum()
```

```
sepal length (cm)    0
sepal width (cm)     0
petal length (cm)    0
petal width (cm)     0
species              0
petal_size           0
dtype: int64
```

Парные диаграммы

```
sns.pairplot(df, hue='species')
plt.show()
```



Ответы на вопросы

Какие способы обработки пропусков использовались?

- Для количественного признака пропуски заполнялись медианой. Медиана устойчива к выбросам и сохраняет распределение признака лучше, чем среднее значение.
- Для категориального признака пропуски заполнялись модой (наиболее частое значение). Данный подход выбран для категориальной переменной, поскольку среднее или медиана для нее не определены.

Какие признаки будут использоваться для построения моделей?

Для построения моделей машинного обучения целесообразно использовать четыре исходных количественных признака, а в качестве целевой переменной использовать species. На парных диаграммах хорошо видно, что классы (виды ирисов) почти линейно разделяются по признакам petal length и petal width, а признаки sepal length и sepal width

дают дополнительную полезную информацию. Признак `petal_size` создан искусственно на основе `petal length (cm)`, поэтому он дублирует информацию исходного количественного признака и его включение одновременно с `petal length` нецелесообразно.

